

## MULTIMODALIDAD EN EL META APRENDIZAJE

Los métodos de aprendizaje profundo han progresado ampliamente en los campos del habla, lenguaje y visualización, aunque su efectividad está directamente relacionada con la disponibilidad de grandes cantidades de datos etiquetados, lo que los vuelve costosos. Esta dificultad ha motivado a los científicos a desarrollar métodos de aprendizaje basados en enseñanzas previas para las nuevas tareas o a realizar tareas de aprendizaje simultáneas con múltiples parámetros en un conjunto. En años recientes se han desarrollado técnicas que modifican el algoritmo de aprendizaje a escenarios multimodales. Los mecanismos de aprendizaje basados en tareas realizadas previamente han inspirado a las ciencias computacionales a emular el aprendizaje a través de tareas previas como lo hacen los humanos, denominándolo meta aprendizaje. Este enfoque permite a las máquinas aprender de las tareas realizadas previamente para el desarrollo de nuevas labores, mejorando su adaptabilidad.

El meta aprendizaje se enfrenta a desafíos al trabajar con tareas más complejas, especialmente cuando las fuentes de datos son multimodales. A pesar de los éxitos previos del meta aprendizaje en varios contextos, su uso inteligente con tareas de modalidades heterogéneas presenta retos únicos para los investigadores. Algunos estudios han avanzado en la aplicación de métodos de meta aprendizaje a tareas con patrones de modalidades diferentes. A pesar de posibles problemas de datos perdidos o desbalanceados, integrar las fortalezas de las diferentes modalidades puede mejorar el rendimiento en el contexto del meta-aprendizaje. El marco de entrenamiento del meta-aprendizaje puede aumentar la capacidad de generalización del aprendiz original basado en multimodalidad para nuevas tareas.

En el meta aprendizaje, primero se identifican combinaciones de tareas con diferentes modalidades, como tareas similares con datos faltantes o tareas diferentes con datos mixtos. Posteriormente, cada tipo de dato se codifica para enriquecer el modelo. Un modelo principal, entrenado mediante algoritmos de meta entrenamiento, aprende a generalizar a nuevas tareas. Los procesos auxiliares ayudan a resolver problemas específicos de la multimodalidad, como generar datos faltantes o mapear diferentes tipos de datos a un espacio común. Este enfoque mejora el proceso de entrenamiento y la capacidad del modelo para generalizar a nuevas tareas con datos multimodales.

La multimodalidad permite que los modelos puedan generalizar mejor a nuevas tareas y contextos, aprovechando las fortalezas de cada tipo de dato. El meta aprendizaje surgió en la década de 1980 y ha evolucionado significativamente desde entonces, especialmente con la llegada del aprendizaje automático y la inteligencia artificial. La formalización del meta aprendizaje implica el desarrollo de algoritmos que permiten a los sistemas aprender a aprender. Esto incluye la creación de marcos teóricos y prácticos que guían cómo los modelos pueden adaptarse y mejorar continuamente a través de diferentes tareas y datos. Los principales retos incluyen la integración efectiva de diferentes modalidades, la gestión de datos desbalanceados o faltantes, y la mejora de la capacidad de generalización de los modelos en nuevas tareas.

El metaaprendizaje permite que los modelos aprendan a aprender, permitiendo adaptarse rápidamente a nuevas tareas con pocos datos de entrenamiento. Durante el embedding, el metaaprendizaje se centra en aprender representaciones de datos que sean útiles para múltiples tareas y que estos capturen las características importantes para que puedan ser reutilizadas en diferentes escenarios. Para la etapa de generación de datos (Meta Conocimiento), el modelo aprende a generar nuevos datos o características a partir de conocimientos previos.

La inicialización modal parametrizada implica alinear las diferentes modalidades dentro de una tarea (within-task modality alignment) y entre diferentes tareas (cross-task modality alignment),

procurando que las representaciones de datos sean coherentes y útiles en múltiples contextos. El optimizador modal unificado es un algoritmo que ajusta los parámetros de manera en que todas las modalidades de datos trabajen juntas de la mejor manera posible, optimizando su interacción para obtener los mejores resultados.

En resumen, el aprendizaje del embedding en el metaaprendizaje multimodal implica crear representaciones vectoriales coherentes y útiles para diferentes tipos de datos y tareas. Las redes modales emparejadas y unificadas, junto con las metodologías de prototipos deterministas y desplazados, ayudan a optimizar este proceso y mejorar la capacidad de los modelos para generalizar. El enfoque de coincidencia modal incluye la alineación y sincronización de diferentes modalidades de datos y permite que los modelos aprovechen al máximo las fortalezas de cada tipo y mejoren su capacidad de generalización y adaptación a nuevas tareas

El metaaprendizaje es particularmente útil para la clasificación de imágenes y tareas multivariadas porque puede aprender eficientemente de una cantidad limitada de datos, generalizar rápidamente a nuevas tareas y adaptarse a cambios en los datos. Esto es esencial para situaciones donde obtener grandes conjuntos de datos etiquetados es difícil, y donde las características aprendidas de unas pocas imágenes pueden aplicarse a otras, mejorando la precisión y eficiencia del modelo. El metaaprendizaje enfrenta desafíos como la integración efectiva de múltiples modalidades, el manejo de datos desbalanceados o faltantes, y la necesidad de hacer los modelos más interpretables y transparentes.

## Discusión

La multimodalidad en el meta aprendizaje ha mejorado exponencialmente en años recientes gracias al desarrollo y adaptación de algoritmos que permiten aprender de tareas pasadas para el desarrollo de nuevas. Este tipo de aprendizaje es capaz de trabajar con una cantidad limitada de datos pero generando nuevos con el avance de su entrenamiento. Sus aplicaciones son especialmente útiles para tareas de clasificación de imágenes y multivariada. Aunque aún hay áreas por desarrollar, este tipo de aprendizaje basado en "experiencia" permite a las máquinas aprender a aprender. Además, el meta aprendizaje mejora la capacidad de generalización y adaptación a nuevas tareas, resolviendo problemas complejos en diversos campos y potenciando la eficiencia de los algoritmos de optimización. Al utilizar representaciones vectoriales y técnicas avanzadas de alineación modal, este enfoque ha revolucionado la manera en que los modelos pueden manejar datos de diversas fuentes, integrando información de múltiples modalidades para una comprensión más rica y completa. La continua investigación y perfeccionamiento de estas técnicas promete aún más avances significativos en el futuro.

## Referencia

Ma, Y., Zhao, S., Wang, W., Li, Y., & King, I. (2022). Multimodality in meta-learning: A comprehensive survey. *Knowledge-Based Systems*, 250, 108976.